



Amirkabir University of Technology  
(Tehran Polytechnic)



Electrical Engineering Department

گزارشکار آزمایشگاه مقدمه‌ای بر هوش محاسباتی

آزمایش شماره‌های 3

## MultiLayer Perceptron

نام استاد: محمدحسین امینی

نام دانشجو: محمدعشریا ثمودی - 9723021


### آزمایش سوم

هدف آزمایش: پیاده‌سازی مدل شبکه عصبی چندلایه

شرح آزمایش:

#### 1. مقدمه

مدل‌های شبکه SLP دارای مشکلات زیاد و محدودیت در استفاده می‌باشند که از جمله آنها می‌توان به ناتوانی آن در مقابله با غیرخطی بودن و محدودیت در مقدار و تعداد خروجی اشاره کرد که راه حل این مشکلات شبکه‌های MLP هستند. شبکه SLP توانایی تشخیص داده‌های جدپذیر خطی را داشت.



این شبکه از قسمت های مختلفی تشکیل شده اند:

1. لایه ی ورودی (input layer)
2. لایه ی مخفی (hidden layer)
3. لایه ی خروجی (output layer)
4. وزن ها و بایاس ها
5. توابع فعال ساز

یادگیری در شبکه عصبی با تغییر وزن اتصال پس از پردازش هر قطعه از داده ها، براساس میزان خطا در خروجی در مقایسه با نتیجه مورد انتظار رخ می دهد.

روش های بسیاری برای استفاده از MLP وجود دارد که یکی از مهم ترین آنها روش Back-Propagation Training یا روش پس انتشار خطا است. در این روش، در هر دور (یعنی در هر تکرار) دو مرحله خواهیم داشت. مرحله ی اول حرکت رو به جلو (feed forward) است که، با ضرب داده های ورودی در وزن ها و سپس جمع آن با انحراف انجام می شود.

$$\mathcal{E}(n) = \frac{1}{2} \sum_j e_j^2(n)$$

با استفاده از گرادیان، تغییر در وزن به صورت زیر است:

$$\Delta w_{ji}(n) = -\eta \frac{\partial \mathcal{E}(n)}{\partial v_j(n)} y_i(n)$$

$$-\frac{\partial \mathcal{E}(n)}{\partial v_j(n)} = e_j(n) \phi'(v_j(n))$$

$$-\frac{\partial \mathcal{E}(n)}{\partial v_j(n)} = \phi'(v_j(n)) \sum_k -\frac{\partial \mathcal{E}(n)}{\partial v_k(n)} w_{kj}(n)$$

سرانجام در همان مرحله ی اول به یک خروجی می رسیم که احتمالاً با خروجی واقعی تفاوت دارد. اینجاست که توسط تابع ضرر مشخص می کنیم که مرحله ی feed forward چه مقدار خطایی داشته است. حال که فهمیدیم الگوریتم با توجه به وزن ها و انحراف ها چه مقدار خطایی دارد، به مرحله ی دوم در یک تکرار می رویم. در این مرحله می توانیم به عقب بازگشته و وزن ها و انحراف ها را به هنگام سازی کنیم.

یعنی وزن ها و انحراف ها را به شکلی تغییر دهیم تا در تکرار بعدی نتیجه ای نزدیک تر به خروجی واقعی و با خطای کم تر را تولید کنند. این تکرار ها آنقدر انجام می شود تا خروجی شبکه برای تمامی داده های آموزشی، به نزدیک ترین

مقدار واقعی خود (یعنی مقداری که توسط داده‌های آموزشی در اختیار داریم) برسد. به این ترتیب الگوریتم یاد می‌گیرد.

در قسمت ابتدائی، بردار وزن  $w_1$  و  $w_2$  و همچنین بایاس‌های  $b_1$  و  $b_2$  را تعریف می‌کنیم.

```
class MLP:

    def __init__(self,x,y,hidden_neurons = 5):
        self.x = x
        self.y = y
        self.hidden_neurons = hidden_neurons
        self.w1 = np.random.rand(x.shape[0],hidden_neurons)
        self.b1 = np.random.rand(1,hidden_neurons)
        self.w2 = np.random.rand(hidden_neurons,y.shape[0])
        self.b2 = np.random.rand(1,y.shape[0])
```

سپس در حلقه ای به ازای تعداد epochs های ورودی، خروجی لایه‌ی اول را با ضرب وزن ها در ورودی و عبور از تابع فعال ساز بدست می‌آوریم. حال خروجی لایه‌ی دوم را نیز بدست آورده و با محاسبه‌ی خروجی نهایی مسیر feedforward را کامل می‌کنیم.

```
def fit(self,iteration = 10000):

    for iter in range(iteration):
        self.costfunc = 0
        z = np.dot(self.x,self.w1) + self.b1
        hiddenlayeroutput = sigmoid(z)
        z = np.dot(hiddenlayeroutput,self.w2) + self.b2
        output = sigmoid(z)

        # calculating cost function
        self.costfunc = 0.5* np.sum(np.power((self.y-output),2))
        outputerror = 0.5 * (self.y - output) * (1- np.power(output,2))
        hiddenerror = 0.5 * (1 -np.power(hiddenlayeroutput,2))* (outputerror * self.w2.T)

        # update weights
        ar = 0.1
        self.w2 += ar*np.dot(hiddenout.T ,outputerror)
        self.w1 += ar*np.dot(self.x.T , hiddenerror)

        # update biases
        self.b2 += np.sum(outputerror) * ar
        self.b1 += np.sum(hiddenerror) * ar

        if costfunc < 0.01:
            break;
```

حال به کامل کردن مسیر فیدبک میپردازیم، مطابق بلوک دیاگرام بالا وزن های دو لایه را آپدیت میکنیم در حلقه تابع هزینه هم محاسبه میشود تا اگر به دقت خوبی برسد از حلقه خارج شود.

```
def predict(self,xpredict):  
    hiddenoutput_predict = self.sigmoid(np.dot(xpred,self.w1)+self.b1)  
    pred = self.sigmoid(np.dot(hiddenoutput_predict,self.w2)+ self.b2)  
    return pred.T
```